

# PostgreSQL

Readme.rmd

Sergio Pedro R Oliveira

2022-09-30

## Contents

<b>1</b>	<b>Objetivo</b>	<b>3</b>
<b>2</b>	<b>Referência</b>	<b>3</b>
<b>3</b>	<b>Aula 117 - Instalação do PostgreSQL, conectando servidor ao pgAdmin 4 e acessando psql</b>	<b>4</b>
3.1	Instalação do <b>PostgreSQL</b>	4
3.2	Conectando <b>pgAdmin 4</b> ao Servidor	4
3.3	Acessando <b>PostgreSQL</b> pelo terminal - psql	5
3.4	Alterando senha do usuario postgres	5
<b>4</b>	<b>Aula 119 - Primeiros passos pgAdmin4</b>	<b>6</b>
4.1	Acessando um banco de dados	6
4.2	Criando um novo banco de dados	6
4.3	Conectando num banco de dados	6
4.4	Abrindo aba para escrever consulta SQL ( <b>Query Tool</b> )	7
<b>5</b>	<b>Aula 120 - datestyle</b>	<b>8</b>
5.1	Padrão de data de sistema	8
5.2	Função datestyle	8
5.3	Configurando um outro padrão de data	8
<b>6</b>	<b>Aula 121 - Abrir arquivo “.sql” no pgAdmin4</b>	<b>10</b>
<b>7</b>	<b>Aula 122 - Introdução a funções de agregação</b>	<b>11</b>
7.1	Teoria	11
7.2	Funções de agregação	11
7.3	<i>Alias</i>	12
7.4	<b>GROUP BY</b>	13
<b>8</b>	<b>Aula 123 - Estatística Básica (LIMIT, ORDER BY e funções de Agregação Média e Soma)</b>	<b>14</b>
8.1	Limite de linhas mostradas numa consulta - LIMIT	14
8.2	<b>ORDER BY</b>	14
8.3	Funções de Agregação	16
<b>9</b>	<b>Aula 124 - Estatística Básica (Teoria medidas de posição e dispersão)</b>	<b>17</b>
9.1	Preparação dos dados para aplicação de estatística básica	17
9.2	Medidas de posição	25
9.3	Medidas de dispersão	31

<b>10 Aula 125 - Análise Estatística</b>	<b>38</b>
<b>11 Aula 126 - Modelagem de Banco de dados X Modelagem Data Science e BI</b>	<b>39</b>
11.1 Modelagem de Banco de dados . . . . .	39
11.2 Modelagem Data Science . . . . .	42
11.3 Modelagem Business Intelligence . . . . .	43
<b>12 Observações</b>	<b>47</b>
12.1 Exportação de dados . . . . .	47
12.2 Breve explicação de Business Intelligence e Data Science . . . . .	47
<b>13 Andamento dos Estudos</b>	<b>48</b>
13.1 Assunto em andamento . . . . .	48

# 1 Objetivo

Estudo dirigido de **PostgreSQL**.

# 2 Referência

Vídeo aulas “O curso completo de Banco de Dados e SQL, sem mistérios” - Udemey.

## 3 Aula 117 - Instalação do PostgreSQL, conectando servidor ao pgAdmin 4 e acessando psql

### 3.1 Instalação do PostgreSQL

#### 3.1.1 Principais programas

- **PostgreSQL**

É um sistema gerenciador de banco de dados objeto relacional (SGBD), desenvolvido como projeto de código aberto, que pode ser baixado pelo site:

<https://www.postgresql.org/download/>

- **pgAdmin 4**

É uma interface web com o banco de dados. Pode ser baixado pelo site:

<https://www.pgadmin.org/download/>

- **psql**

O psql é um front-end baseado em terminal para o PostgreSQL.

- **Sublime Text**

- Sublime Text é um editor de código-fonte multi-plataforma.
- Ele suporta nativamente muitas linguagens de programação e linguagens de marcação.
- Serve para escrever os script's “.sql”, antes de lançar no banco de dados.

### 3.2 Conectando pgAdmin 4 ao Servidor

- Primeiro após fazer as instalações, ao abrir o **pgAdmin 4**, o programa vai pedir para registrar uma senha para proteção do sistema.
- Antes de adicionar o novo servidor no **pgAdmin 4**, é necessário mudar a senha do PostgreSQL, acessando ele pelo terminal, pelo **psql**.

- Assim se torna necessário abrir o terminal e acessar o psql:

```
sudo -u postgres psql  
senha_sudo
```

- Para mudar a senha do usuário postgres, basta digitar o comando:

```
ALTER USER postgres PASSWORD 'novo_password'
```

- Após a mudança da senha, podemos registrar o novo servidor no **pgAdmin 4**.
  - Clicar com o botão esquerdo em “servers” > “Register” > “server”.
  - Na aba “General”, basta adicionar um nome para o server.  
“localhost” [nome mais comum]

- Na aba “Connection” é necessário preencher:
  - \* Hostname: “localhost”
  - \* Port: 5432
  - \* Maintenance database: postgres
  - \* Username: postgres
  - \* Password: [repetir a senha cadastrada anteriormente no psql]
- Ao clicar em “**Salvar**” o novo servidor estará conectado.

### 3.3 Acessando PostgreSQL pelo terminal - psql

- Para acessar o **PostgreSQL** pelo terminal do **UBUNTU** o comando é:  
sudo -u postgres psql  
*senha\_sudo*

### 3.4 Alterando senha do usuario postgres

- O comando para alterar usuário e senha no Postgres pelo terminal é:  
**ALTER USER** postgres **PASSWORD** ‘*novo\_password*’
- Este comando é útil para conectar o servidor a interface *pgAdmin4*, pois necessita criar uma senha para o usuário *postgres*.

## 4 Aula 119 - Primeiros passos pgAdmin4

### 4.1 Acessando um banco de dados

- Para acessar um dos bancos de dados, basta abrir o programa **pgAdmin 4**.
- Inserir a senha de proteção do programa.
- Clickar dentro aba lateral “**Browser**” na opção **Servers** para se conectar ao servidor.
- Inserir a senha do **servidor**.
- Assim, será mostrado o nome do servidor, expandindo ele, será mostrado os bancos de dados que nele estão contidos.
- Entre os bancos de dados disponiveis o “*postgres*” é o bando de dados reservado do sistema.
  - o *postgres* é o nome do root do sistema **PostgreSQL**.

### 4.2 Criando um novo banco de dados

- Na aba lateral “**Browser**”, nas opções **Servers > localhost > Databases**.
- Para criar um novo banco de dados:
  - Clickar na opção **Databases** com o botão direito.
  - Seguir as opções: **Create > Database**.
  - Preencher as opções na aba “**General**”:
    - \* **Database:** [Nome do banco de dados]
    - \* **Owner:** [Responsavel pelo banco de dados]
    - \* **Comment:** [Comentario/resumo sobre o banco de dados, um texto]
    - \* **Save** para criar o banco de dados.
- O novo banco de dados e suas pastas estara disponivel na aba lateral **Browser**, dentro de **Databases**.

### 4.3 Conectando num banco de dados

- Para se conectar a um banco de dados, basta clicar nele na aba lateral “**Browser**”.
- Para verificar em qual banco de dados esta conectado:

- Dentro da aba superior **Dashboard** > na parte inferior da janela, nas opções:
  - \* **User** informa o usuário logado, no momento.
  - \* **Application** informa o banco de dados que esta conectado, no momento.

#### 4.4 Abrindo aba para escrever consulta SQL (Query Tool)

- **Query Tool** é a aba na qual se escreve as instruções SQL.
- Na aba superior, na opção **TOOLS** > **Query Tool**, abre a aba para escrever as instruções **SQL**.

## 5 Aula 120 - datestyle

### 5.1 Padrão de data de sistema

- O padrão de data do sistema é:  
'DD/MM/YYYY', **DMY**.

### 5.2 Função datestyle

- É uma função que mostrar o padrão de data (**DATE**) em que o sistema esta configurado.
- Sintaxe:  
**SHOW DATESTYLE**;

### 5.3 Configurando um outro padrão de data

- No ubuntu:
  - Na pasta:  
/etc/postgresql/14/main/
  - No arquivo “/postgresql.conf”, onde ficam guardadas as configurações do PostgreSQL.
  - Basta abrir com editor de texto (Sublime text, Notepad++, ... ) e procurar por “datestyle”.
  - Para alterar o padrão basta mudar a arrumação das letras e salvar o arquivo.
  - Dado que **dmy** é:
    - \* **d** é day
    - \* **m** é month
    - \* **y** é year
  - Lembrar de salvar comentado em baixo a configuração original antes salvar uma alteração.
  - Reiniciar o servidor (computador), para implementar as mudanças.
- No windows:
  - Na pasta:  
C:/Arquivos de Programas/PostgreSQL/14[*Numero da versão do PostgreSQL*]/data/
  - No arquivo “/postgresql.conf”, onde ficam guardadas as configurações do PostgreSQL.
  - Basta abrir com editor de texto (Sublime text, Notepad++, ... ) e procurar por “datestyle”.
  - Para alterar o padrão basta mudar a arrumação das letras e salvar o arquivo.
  - Dado que **dmy** é:
    - \* **d** é day



- \* **m** é month
- \* **y** é year
- Lembrar de salvar comentado em baixo a configuração original antes salvar uma alteração.
- Reiniciar o servidor, para implementar as mudanças.
  - \* Para reiniciar o servidor, no “executar”, digitar “serviços” e clicar na opção de programa “SERVIÇOS”.
  - \* Dentro de “SERVIÇOS”, o programa vai mostrar todos os serviços do **WINDOWS**, procurar pelo “PostgreSQL”.
  - \* Selecionar o “PostgreSQL” e clicar em “reiniciar o serviço”.
  - \* Voltar no **pgAdmin 4** dar “refresh” na tabela, ou servers.
  - \* Caso a conexão não esteja estabelecida, basta clicar em “**Query Tool**” para restabeler nova conexão.

## 6 Aula 121 - Abrir arquivo “.sql” no pgAdmin4

- Ao iniciar o programa **pgAdmin4**, abrir a aba **Query Tools** de programação **SQL**.
- Com a aba “**Query Tools**” aberta, clicar na opção “**Open File**”, navegar pelas pastas e selecionar o arquivo com extensão “.sql” para abrir.
- O arquivo será aberto na aba “**Query Tools**”.

## 7 Aula 122 - Introdução a funções de agregação

### 7.1 Teoria

- O que são funções de agregação?
  - Funções de agregação são funções SQL que permitem executar uma operação aritmética nos valores de uma coluna em todos os registros de uma tabela.
  - Uma função de agregação executa um cálculo em um conjunto de valores e retorna um único valor.
  - As funções de agregação frequentemente são usadas com a cláusula **GROUP BY** da instrução **SELECT**.
  - As funções de agregação agregam, somam e resumem registros, o que é apreciado em *data science*.

### 7.2 Funções de agregação

- **AVG()**
  - Calcula a média aritmética sobre o conjunto de linhas fornecido.
  - Retorna a média aritmética dos valores dos registros.
  - Sintaxe:  
**SELECT**  
*setor*,  
**AVG(salario) AS** “MEDIA DE SALARIO”  
**FROM** *tabela*  
**GROUP BY** *setor*;
- **COUNT()**
  - Essa função retorna o número de itens encontrados em um grupo.
  - Com exceção da função **COUNT(\*)**, as funções de agregação ignoram valores nulos.
  - Sintaxe:  
**SELECT**  
*setor*,  
**COUNT(nome) AS** “NUMERO FUNCIONARIOS”  
**FROM** *tabela*  
**GROUP BY** *setor*;  
ou  
**SELECT**  
**COUNT(\*) AS** “NUMERO DE REGISTROS”  
**FROM** *tabela*;
- **MIN()**
  - Retorna o valor Mínimo de um conjunto de valores.
  - Sintaxe:  
**SELECT**

```

    setor,
    MIN(salario) AS "MENOR SALARIO DO SETOR"
FROM tabela
GROUP BY setor;

```

- **MAX()**

- Retorna o Valor máximo de um conjunto de valores.

- Sintaxe:

```

SELECT
    setor,
    MAX(salario) AS "MAIOR SALARIO DO SETOR"
FROM tabela
GROUP BY setor;

```

- **SUM()**

- Total (Soma) de um conjunto de valores.

- Sintaxe:

```

SELECT
    setor,
    SUM(salario) AS "TOTAL DE SALARIOS DO SETOR"
FROM tabela
GROUP BY setor;

```

### 7.3 *Alias*

- Um *alias* de coluna permite atribuir um nome temporário a uma coluna ou expressão na lista de projeção de uma instrução **SELECT**.
  - O *alias* da coluna existe temporariamente durante a execução da consulta.
  - É principalmente importante colocar *alias* em colunas que levam formulas, para facilitar o entendimento de quem vai ler a consulta.
  - Sintaxe:
- ```

SELECT
    AVG(coluna1) AS "ALIAS"
...

```

## 7.4 GROUP BY

- A cláusula **GROUP BY** divide as linhas retornadas da instrução **SELECT** em grupos.
- Para cada grupo, você pode aplicar uma função agregada, por exemplo, **SUM()** para calcular a soma dos itens ou **COUNT()** para obter o número de itens nos grupos.
- A cláusula de instrução divide as linhas pelos valores das colunas especificadas na cláusula **GROUP BY** e calcula um valor para cada grupo.
- O **PostgreSQL** avalia a cláusula **GROUP BY** após as cláusulas **FROM** e **WHERE** e antes das cláusulas **HAVING SELECT**, **DISTINCT**, **ORDER BY** e **LIMIT**.



- Sintaxe:  
**SELECT** *Country, Region, SUM(sales) AS "Total Sales"*  
**FROM** *Sales*  
**GROUP BY** *Country, Region;*

## 8 Aula 123 - Estatística Básica (LIMIT, ORDER BY e funções de Agregação Média e Soma)

### 8.1 Limite de linhas mostradas numa consulta - LIMIT

- O comando **LIMIT** determina a quantidade máxima de linhas/registros que serão mostrados de uma determinada consulta.
- O comando vem acompanhado do número de linhas da visualização da consulta.
- Sintaxe:  
**SELECT \* FROM *tabela***  
**LIMIT 10;**

### 8.2 ORDER BY

- A palavra-chave **ORDER BY** é usada para classificar o conjunto de resultados em ordem crescente ou decrescente.
- A ordem na qual as linhas são retornadas em um conjunto de resultados não é garantida, a menos que uma cláusula **ORDER BY** seja especificada.
- **ORDER BY** organiza os resultados de acordo com uma ou mais colunas da tabela, podendo definir a ordem do resultados como crescente ou decrescente.
  - **ASC**  
Classifica os registros em ordem crescente.
  - **DESC**  
Classifica os registros em ordem decrescente.
- A palavra-chave **ORDER BY** classifica os registros em ordem crescente por padrão. Para classificar os registros em ordem decrescente, use a palavra-chave **DESC**.
- Várias colunas de classificação podem ser especificadas. Os nomes de coluna devem ser exclusivos. A sequência das colunas de classificação na cláusula **ORDER BY** define a organização do conjunto de resultados classificado. Ou seja, o conjunto de resultados é classificado pela primeira coluna e então essa lista ordenada é classificada pela segunda coluna e assim por diante.
- É possível ao invés de especificar o nome do campo/coluna no **ORDER BY**, substituir pela posição em que a coluna aparece na cláusula **SELECT**. Porém não é entendida por outros bancos de dados e usuários com tanta facilidade quanto com a especificação do nome de coluna real. Além disso, as alterações na lista de seleção, como a alteração da ordem das colunas ou a adição de novas colunas, exigirão a modificação da cláusula **ORDER BY** para evitar resultados inesperados.
- Sintaxe com exemplo:  
**SELECT \* FROM *Customers***

**ORDER BY** *Country* **ASC**, *CustomerName* **DESC**;

## 8.3 Funções de Agregação

### 8.3.1 Média - AVG

- A função **AVG()**, retorna a média dos valores em um grupo.
- Ignora valores nulos.
- Sintaxe:  
**SELECT**  
**AVG**(*preco*) **AS** "PRECO\_MEDIO"  
**FROM** *produto*;

### 8.3.2 Soma - SUM

- A função **SUM()**, retorna a soma de todos os valores, ou somente os valores **DISTINCT** na expressão.
- **SUM()** pode ser usado exclusivamente com colunas numéricas.
- Valores nulos são ignorados.
- Sintaxe:  
**SELECT**  
*nome*,  
**SUM**(*valor*) **AS** "TOTAL\_RECEBIDO"  
**FROM** *produto*  
**GROUP BY** *id*;



## 9 Aula 124 - Estatística Básica (Teoria medidas de posição e dispersão)

### 9.1 Preparação dos dados para aplicação de estatística básica

#### 9.1.1 Teoria

- Definição de Estatística:  
A Estatística de uma maneira geral compreende aos métodos científicos para COLETA, ORGANIZAÇÃO, RESUMO, APRESENTAÇÃO e ANÁLISE de Dados de Observação (Estudos ou Experimentos), obtidos em qualquer área de conhecimento. A finalidade é a de obter conclusões válidas para tomada de decisões.
  - Estatística Descritiva  
Parte responsável basicamente pela COLETA e SÍNTESE (Descrição) dos Dados em questão. Disponibiliza de técnicas para o alcance desses objetivos. Tais Dados podem ser provenientes de uma AMOSTRA ou POPULAÇÃO.
  - Estatística Inferencial  
É utilizada para tomada de decisões a respeito de uma população, em geral fazendo uso de dados de amostrais. Essas decisões são tomadas sob condições de INCERTEZA, por isso faz-se necessário o uso da TEORIA DA PROBABILIDADE.
- O fluxograma da estatística descritiva pode ser esboçado da seguinte forma:



- A representação tabular (Tabelas de Distribuição de Frequências) deve conter:
  - Cabeçalho  
Deve conter o suficiente para que as seguintes perguntas sejam respondidas “**o que?**” (Relativo ao fato), “**onde?**” (Relativo ao lugar) e “**quando?**” (Correspondente à época).
  - Corpo  
É o lugar da Tabela onde os dados serão registrados. Apresenta colunas e sub colunas.
  - Rodapé  
Local destinado à outras informações pertinentes, por exemplo a Fonte dos Dados.
- População e Amostras
  - População  
É o conjunto de todos os itens, objetos ou pessoas sob consideração, os quais possuem pelo menos uma característica (Variável) em comum. Os elementos pertencentes à uma População são denominados “Unidades Amostrais”.
  - Amostras  
É qualquer subconjunto (não vazio) da População. É extraída conforme regras pré-estabelecidas, com a finalidade de obter “estimativa” de alguma Característica da População.

- Tipos de variáveis



- *Qualitativo nominal*  
Não possuem uma ordem natural de ocorrência.
- *Qualitativo ordinal*  
Possuem uma ordem natural de ocorrência.
- *Quantitativo discreta*  
Só podem assumir valores inteiros, pertencentes a um conjunto finito ou enumerável.
- *Quantitativo contínua*  
Podem assumir qualquer valor em um determinado intervalo da reta dos números reais.

### 9.1.2 Preparação dos dados (sumariar dados coletados)

- Frequência (conceito)  
É a quantidade de vezes que um valor é observado dentro de um conjunto de dados.
- Distribuição em frequências
  - A distribuição tabular é denominada: “Tabela de Distribuição de Frequências”.
  - Podemos separar em 3 modelos de distribuição tabular:
    - \* Variável Quantitativa Discreta.
    - \* Variável Quantitativa Contínua.
    - \* Variáveis Qualitativas.

### 9.1.2.1 Variável Quantitativa Discreta

- Passos da preparação dos dados:
  - 1º Passo - **DADOS BRUTOS**: Obter os dados da maneira que foram coletados.
  - 2º Passo - **ROL**: Organizar os DADOS BRUTOS em uma determinada ordem (crescente ou decrescente).
  - 3º Passo - **CONSTRUÇÃO TABELA**: Na primeira coluna são colocados os valores da variável, e nas demais as respectivas frequências.
  - Frequência absoluta simples (Nº de vezes que cada valor da variável se repete).
- Principais campos da **distribuição tabular de variáveis quantitativas discretas**:
  - $n$  é o número total de elementos da amostra.
  - $x_i$  é o número de valores distintos que a variável assume.
  - $F_i$  é a Frequência Absoluta Simples.
  - $f_i$  é a Frequência Relativa Simples.
  - $f_i\%$  é a Frequência Relativa Simples Percentual.  $f_i\% = f_i \cdot 100\%$ .
  - $F_a$  é a Frequência Absoluta Acumulada.

| $x_i$ | $F_i$ | $f_i$ | $f_i\%$ | $F_a \downarrow$ | $F_a \uparrow$ | $f_a \downarrow$ | $f_a \uparrow$ |
|-------|-------|-------|---------|------------------|----------------|------------------|----------------|
| 0     | 6     | 0,2   | 20      | 6                | 30             | 0,2              | 1              |
| 1     | 11    | 0,37  | 37      | 17               | 24             | 0,57             | 0,8            |
| 2     | 8     | 0,27  | 27      | 25               | 13             | 0,84             | 0,43           |
| 3     | 2     | 0,07  | 7       | 27               | 5              | 0,91             | 0,16           |
| 4     | 2     | 0,06  | 6       | 29               | 3              | 0,97             | 0,09           |
| 6     | 1     | 0,03  | 3       | 30               | 1              | 1                | 0,03           |
| Total | 30    | 1     | 100     | -                | -              | -                | -              |


Obs.: As setas simbolizam ordem crescente ou decrescente.

### 9.1.2.2 Variável Quantitativa Contínua

- Teoria:
  - A construção da representação tabular é realizada de maneira análoga ao caso das variáveis discretas.
  - As frequências são agrupadas em classes, denominadas de “Classes de Frequência”.
  - Denominada “Distribuição de Frequências em Classes” ou “Distribuição em Frequências Agrupadas”.

Dist. Frequências “X ~ Nº de Acidentes por dia, na BR 101, Setembro de 2015

Nova Representação!



| $x_i$ | $F_i$ | $f_i$ | $f_i\%$ | $Fa\downarrow$ | $Fa\uparrow$ | $fa\downarrow$ | $fa\uparrow$ |
|-------|-------|-------|---------|----------------|--------------|----------------|--------------|
| 0     | 6     | 0,2   | 20      | 6              | 30           | 0,2            | 1            |
| 1     | 11    | 0,37  | 37      | 17             | 24           | 0,57           | 0,8          |
| 2     | 8     | 0,27  | 27      | 25             | 13           | 0,84           | 0,43         |
| 3     | 2     | 0,07  | 7       | 27             | 5            | 0,91           | 0,16         |
| 4     | 2     | 0,06  | 6       | 29             | 3            | 0,97           | 0,09         |
| 6     | 1     | 0,03  | 3       | 30             | 1            | 1              | 0,03         |
| Total | 30    | 1     | 100     | -              | -            | -              | -            |

Fonte: Governo Federal

- Convencionar o tipo de intervalo para as classes de frequência:
  - Intervalo “exclusive – exclusive”:  $x_i \text{ --- } x_j$
  - Intervalo “inclusive – exclusive”:  $x_i |--- x_j$
  - Intervalo “inclusive – inclusive”:  $x_i |---| x_j$
  - Intervalo “exclusive – inclusive”:  $x_i \text{ ---}| x_j$

OBS.:  $x_i$  - Limite Inferior (LI) de Classe;

$x_j$  - Limite Superior (LS) de Classe;

#### Premissas



- As classes têm que ser exaustivas, isto é, todos os elementos devem pertencer a alguma classe;
- As classes têm que ser mutuamente exclusivas, isto é, cada elemento tem que pertencer a uma única classe

Passos para contruir a **Tabela Distribuição de Frequências Contínua**:

1. Como estabelecer o **número de classes** ( $k$ ):

- Normalmente varia de 5 a 20 classes.
- Critério fórmula de Sturges:

$$k \cong 1 + 3,3 \cdot \log(n)$$

- Critério da Raiz quadrada:

$$k \cong \sqrt{n}$$

Onde  $n$  é o número de elementos amostrais.

2. Como calcular a **Amplitude Total** ( $AT_x$ ):

- Diferença entre o maior e o menor valor observado.
- Intervalo de variação dos valores observados.
- Aproximar valor calculado para múltiplo do nº classes ( $k$ ).
- Garantir inclusão dos valores mínimo e máximo.
- Cálculo:

$$AT_x = Máx(X_i) - Mín(X_i)$$

Onde,

$AT_x$  é a Amplitude Total.

$Máx(X_i)$  é o *valor máximo das amostras*.

$Mín(X_i)$  é o *valor mínimo das amostras*.

- Exemplo:  
Se  $k = 5$ ,  
 $AT_x = 28$   
Logo, arredondando  $AT_x = 30$ , para aproximar o valor  $AT_x$  de um múltiplo de  $k$ .

3. Como calcular a **Amplitude das classes da frequência** ( $h$ ):

- As classes terão amplitudes iguais.
- Cálculo:

$$h = h_i = \frac{AT_x}{k}$$

Onde,  $k$  é o **número de classes** e  $AT_x$  é a **Amplitude Total**.

4. Como determinar o ponto médio das classes, representatividade da classe ( $p_i$ ):

$$p_i = \frac{(LS_i - LI_i)}{2}$$

Onde,

$LS_i$  é o limite superior da classe.

$LI_i$  é o limite inferior da classe.

5. Passos da preparação dos dados:

- 1º Passo - **DADOS BRUTOS**: Obter os dados da maneira que foram coletados.
- 2º Passo - **ROL**: Organizar os DADOS BRUTOS em uma determinada ordem (crescente ou decrescente).
- 3º Passo - **CONSTRUÇÃO TABELA**: Na primeira coluna são colocados as classes, e nas demais as respectivas frequências.
- Exemplo:

| Nº Classe | Classes (xi) | Fi | fi   | fi% | Fa↓ | Fa↑ | fa↓  | fa↑  | fa↓% | pi   |
|-----------|--------------|----|------|-----|-----|-----|------|------|------|------|
| 1         | 45  --- 52   | 3  | 0,08 | 8   | 3   | 40  | 0,08 | 1    | 100  | 48,5 |
| 2         | 52  --- 59   | 7  | 0,18 | 18  | 10  | 37  | 0,26 | 0,92 | 92   | 55,5 |
| 3         | 59  --- 66   | 11 | 0,28 | 28  | 21  | 30  | 0,53 | 0,75 | 75   | 62,5 |
| 4         | 66  --- 73   | 10 | 0,25 | 25  | 31  | 19  | 0,78 | 0,47 | 47   | 69,5 |
| 5         | 73  --- 80   | 4  | 0,10 | 10  | 35  | 9   | 0,88 | 0,22 | 22   | 76,5 |
| 6         | 80  --- 87   | 4  | 0,10 | 10  | 39  | 5   | 0,98 | 0,12 | 12   | 83,5 |
| 7         | 87  --- 94   | 1  | 0,02 | 2   | 40  | 1   | 1,00 | 0,02 | 2    | 90,5 |
| Total     |              | 40 | 1,00 | 100 | -   | -   | -    | -    |      | -    |

Fonte: Dados Fictícios

$X_i$  são as classes.

$F_i$  é a Frequência Absoluta Simples.

$f_i$  é a Frequência Relativa Simples.

$f_i\%$  é a Frequência Relativa Simples Percentual.

$F_a$  é a Frequência Absoluta Acumulada.

$f_a$  é a Frequência Absoluta Acumulada Simples.

$f_a\%$  é a Frequência Absoluta Acumulada Simples Percentual.

$p_i$  é a Representatividade da classe (ponto médio das classes).

### 9.1.2.3 Variáveis Qualitativas

- Passos da preparação dos dados:
  - Análogo ao procedimento para dados discretos.
  - 1º Passo - **DADOS BRUTOS**: Obter os dados da maneira que foram coletados.
  - 2º Passo - **ROL**: Nesse caso é feita organização dos DADOS BRUTOS em ordem (Crescente ou Decrescente) de importância.
  - 3º Passo - **CONSTRUÇÃO TABELA** (Com duas ou mais colunas).
- Distribuição de Frequência:
  - $x_i$  é o número de valores distintos que a variável assume.
  - $F_i$  é a Frequência Absoluta Simples.
  - $f_i$  é a Frequência Relativa Simples.
  - $f_i\%$  é a Frequência Relativa Simples Percentual.
  - Inserir comentário sobre os dados.



## 9.2 Medidas de posição

- Localizar a *maior concentração de valores* de uma distribuição.
- *Sintetizar o comportamento* do conjunto do qual ele é originário.
- Possibilitar a *comparação* entre séries de dados.
- As principais **medidas de posição** são:
  - **Média Aritmética** (Simples e Ponderada)
  - **Mediana**
  - **Moda**
  - **Separatrizes**
- Medidas de posição comparação:

| Medidas de Posição - Comparação |                               |                                   |                                                      |
|---------------------------------|-------------------------------|-----------------------------------|------------------------------------------------------|
| Medida                          | Definição                     | Vantagens                         | Desvantagens                                         |
| Média                           | Centro da Distribuição        | Reflete todos os valores          | É afetada por valores extremos                       |
| Mediana                         | Divide a distribuição ao meio | Menos sensível a valores extremos | Difícil determinar para grandes quantidades de dados |
| Moda                            | Valor mais frequente          | Valor típico                      | Não é utilizado em análises matemáticas              |

### 9.2.1 Média Aritmética (Simples e Ponderada)

- **Média Aritmética Simples**, dados Não-Agrupados (não tabelados):

- **Média Aritmética** ( $\bar{x}$ ) é o valor médio dos dados da distribuição.
- É a soma de todos os elementos, dividido pelo número total de elementos.
- Cálculo:

$$\bar{x} = \frac{Soma}{n_{Total}}$$

- **Média Aritmética Ponderada**, dados Agrupados (tabelados):

- Atribui-se um peso a cada valor da série.
- É o *Ponto Médio das Classes* ( $p_i$ ), multiplicado por suas respectivas *Frequência Absoluta Simples* ( $F_i$ ), somadas. Dividido pelo *Número Total de Elementos da Amostra* ( $n$ ).
- Cálculo:

$$\bar{x} = \frac{\sum_{i=1}^n p_i \cdot F_i}{n_{Total}}$$

ou,

$$\bar{x} = \frac{(p_1 \cdot F_1) + (p_2 \cdot F_2) + (p_3 \cdot F_3) + \dots}{n_{Total}}$$

### 9.2.2 Mediana ( $md(x)$ )

#### 9.2.2.1 Mediana Discreta

- Com dados em ROL, é o valor que divide o conjunto de dados em duas partes iguais.
- No caso de número de elementos ímpar, a mediana ( $md(x)$ ) é o elemento central.
- No caso de número de elementos par, a mediana ( $md(x)$ ) é a média aritmética simples dos valores centrais:

$$md(x) = \frac{x_{\frac{n}{2}} + x_{\frac{n+1}{2}}}{2}$$

Onde,  
 $x$  é a posição do elemento;  
 $n$  é o número total de elementos.

#### 9.2.2.2 Mediana Contínua

- Mediana ( $md$ ) em distribuição de frequência em variável contínua (dados agrupados em classes):
  1. Fazer a coluna da **Frequência Absoluta Acumulada**, que é o somatório das frequências ao longo das classes.
  2. Definindo o **Intervalo da Mediana**.
    - Obter o número total de elementos  $n$  (somatório das frequências de classes),

$$n = \sum f_i$$

- Determinar a posição do elemento do meio do somatório das frequências:

$$x = \frac{\sum f_i}{2}$$

- A classe que contém essa posição  $x$  na **Frequência Absoluta Acumulada** é a classe do *intervalo da mediana*.
- 3. Cálculo da Mediana:

$$md = Li + \left( \frac{\frac{\sum f_i}{2} - Fa_{anterior}}{f_{intervalo}} \cdot h \right)$$

Onde,  
 $Li$  é o limite inferior do *intervalo da mediana*;  
 $\sum f_i$  é o somatório das frequências (**frequência total** ( $n$ ));  
 $Fa_{anterior}$  é a **Frequência Absoluta Acumulada** da classe anterior (linha anterior ao *intervalo da mediana*);  
 $f_{intervalo}$  é a **Frequência Absoluta Simples** do *intervalo da mediana*;  
 $h$  é a Amplitude da classe do *intervalo da mediana*.

$$h = Ls - Li$$

### 9.2.3 Moda

- Moda ou  $Mo(x)$ : Valor com maior frequência de ocorrência em uma distribuição.
- Podem haver mais de um valor distinto com maior frequência, podendo assim ter mais de um valor na moda.
- Moda com frequência Continua:

#### 1. **Moda Bruta** ( $M_{Bruta}$ ):

- Achar a classe com maior frequência, esse será o *Intervalo Modal*.
- Calcular o *Ponto Médio* (Representatividade da classe) do *Intervalo Modal*:

$$PM = \frac{LS + LI}{2}$$

Onde,

LS = Limite superior da classe;

LI = Limite inferior da classe.

- O *Ponto Médio* do *Intervalo Modal* será a **Moda Bruta** ( $M_{Bruta}$ ).

#### 2. **Moda King** ou **Moda do Rei** ( $M_{King}$ ):

- Determinar o intervalo (classe) com maior frequência, esse será o *Intervalo Modal*.
- Cálculo da Moda de King ( $M_{King}$ ):

$$M_{King} = LI + \left( \frac{F_{post}}{F_{post} + F_{ant}} \cdot h \right)$$

Onde,

LI é o limite inferior da classe do *Intervalo Modal*;

$F_{post}$  é a frequência da classe posterior ao *Intervalo Modal*;

$F_{ant}$  é a frequência da classe anterior ao *Intervalo Modal*;

$h$  é a amplitude do intervalo da classe

$$h = LS - LI$$

#### 3. **Moda de Czuber** ( $M_{Czuber}$ ):

- Determinar o intervalo (classe) com maior frequência, esse será o *Intervalo Modal*.
- Cálculo da **Moda de Czuber** ( $M_{Czuber}$ ):

$$M_{Czuber} = LI + \left( \frac{\Delta_{ant}}{\Delta_{ant} + \Delta_{post}} \cdot h \right)$$

Onde,

LI é o limite inferior da classe do *Intervalo Modal*;

$\Delta_{ant}$  é a variação (diferença) da frequência da classe anterior (ao *Intervalo Modal*) com o *Intervalo*

*Modal* (classe com maior frequência)

$$\Delta_{ant} = |F_i - F_{i-1}|$$

$\Delta_{post}$  é a variação (diferença) da frequência da classe posterior (ao *Intervalo Modal*) com o *Intervalo Modal* (classe com maior frequência)

$$\Delta_{ant} = |F_i - F_{i+1}|$$

$h$  é a amplitude do intervalo da classe

$$h = LS - LI$$

### 9.2.4 Separatrizes

- **Separatrizes** são valores da distribuição que a dividem em partes quaisquer.
- A **mediana**, apesar de ser uma medida de tendência central, é também uma **separatriz** de ordem 1/2, ou seja, divide a distribuição em duas partes iguais.
- As **separatrizes** mais comumente usadas são:
  - **Quartis**  
Dividem a distribuição em quatro partes iguais, de ordem 1/4.
  - **Decis**  
Dividem a distribuição em 10 partes iguais, de ordem 1/10.
  - **Centis**  
Dividem a distribuição em 100 partes iguais, de ordem 1/100.
- Fórmula das Separatrizes:

#### 1. Achar o **Intervalo da separatriz**

- É a classe em que se encontra a separatriz procurada.
- Fazer a coluna de **Frequencia Absoluta Acumulada** ( $F_a$ ).
- É o somatório das frequências (total das frequências), multiplicado pela fração da separatriz procurada ( $k$ ). O resultado é a posição da frequência na coluna **Frequencia Absoluta Acumulada** ( $F_a$ ).

$$P_k = k \cdot \sum f_i$$

A classe na qual a posição pertence é o **Intervalo da separatriz**.

#### 2. Cálculo da separatriz:

$$Sp = L_i + \left( \frac{k \cdot \sum f_i - Fa_{anterior}}{f_{Intervalo}} * h \right)$$

Onde,

$L_i$  é o limite inferior do **Intervalo da separatriz**;

$k$  é a fração (porcentagem) da separatriz procurada;

$\sum f_i$  é o somatório das frequências;

$Fa_{anterior}$  é a **Frequência Absoluta Acumulada** da classe anterior ao **intervalo da separatriz**;

$f_{Intervalo}$  é a **Frequência Absoluta Simples** do **intervalo da separatriz**;

$h$  é a **Amplitude** da classe (limite superior - limite inferior da classe).

$$h = Ls - Li$$

#### 3. Cálculo de **Amplitude Interquartil** ( $AI$ ):

- É a diferença entre 3º quartil e o 1º quartil.

$$AI = Q_3 - Q_1$$

- Para descobrir os valores dos Quartis ( $Q_1$  e  $Q_3$ ) basta usar o *cálculo das separatrizes*.

### 9.3 Medidas de dispersão

- Medem o grau de **variabilidade** (dispersão) dos valores observados em torno da **Média Aritmética**.
- Caracterizam a **representatividade da média** e o nível de **homogeneidade** ou **heterogeneidade** dentro de cada grupo analisado.



#### 9.3.1 Amplitude Total ( $A_T$ )

- Diferença entre o maior e o menor dos valores da série.
- Não considera a dispersão dos valores internos, apenas os extremos.
- Utilização limitada enquanto medida de dispersão, oferece pouca informação.
- Cálculo:

$$A_T = X_{Máx} - X_{Mín}$$

Onde,

$X_{Máx}$  é o valor máximo da série;

$X_{Mín}$  é o valor mínimo da série.

### 9.3.2 Desvio

#### 9.3.2.1 Desvio Absoluto ( $D$ )

- Para dados não agrupados:
  - Os **Desvios Absolutos** ( $D$ ) são a diferença absoluta entre um valor observado e a média aritmética:

$$D = |x_i - \bar{X}|$$

Onde,  
 $x_i$  é o **valor de cada elemento**;  
 $\bar{x}$  é a **Média Aritmética**.

- Os **Desvios Absolutos** ( $D$ ) são um conjunto de elementos como resposta final.
- Para dados agrupados, sem intervalo de classe:
  - Cálculo:

$$d_i = |x_i - \bar{X}|$$

Onde,  
 $x_i$  é o valor da variável discreta;  
 $\bar{X}$  é a **Média Aritmética**.

- Para dados agrupados, com intervalo de classe:
  - Cálculo:

$$d_i = |p_i - \bar{x}|$$

Onde,  
 $p_i$  é a **Representatividade da classe** (ponto médio da classe);  
 $\bar{x}$  é a **Média Aritmética** calculada para *dados agrupados contínuos*:

$$\bar{x} = \frac{\sum_{i=1}^N p_i \cdot f_i}{\sum f_i}$$



### 9.3.2.2 Desvio Absoluto Médio ( $dm$ )

- É a **Média** dos **Desvios**.
- Para dados não agrupados:
  - Cálculo:

$$dm(x) = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

Onde,  
 $x_i$  é o **valor de cada elemento**;  
 $\bar{x}$  é a **Média Aritmética**;  
 $n$  é o **número total de elementos** (frequencia total).

- Para dados agrupados, sem intervalo de classe:
  - Cálculo:

$$D_M = \frac{\sum |d_i| \cdot f_i}{n}$$

Onde,  
 $d_i$  é o **Desvio Absoluto** para dados agrupados, sem intervalo de classe;  
 $f_i$  é a **Frequência** de cada variável discreta;  
 $n$  é o número total de elementos (ou somatório das frequências).

- Para dados agrupados, com intervalo de classe:
  - Cálculo:

$$D_M = \frac{\sum |d_i| \cdot f_i}{\sum f_i}$$

Onde,  
 $d_i$  é o **Desvio Absoluto** para dados agrupados, com intervalo de classe;  
 $f_i$  é a **frequência** de cada intervalo de classe.

### 9.3.3 Variância ( $\sigma^2$ ou $S^2$ )

- Leva em consideração os valores extremos e também os valores intermediários.
- Relaciona os desvios em torno da média (destâncias dos valores ate a média).
- Média Aritmética dos quadrados dos desvios.
- O símbolo para **Variância Populacional** é o sigma ao quadrado ( $\sigma^2$ ), já o símbolo para **Variância Amostral** é o “S” maiusculo ao quadrado ( $S^2$ ).
- Cálculo para dados não agrupados:

– População

$$\sigma^2 = \sum_{i=1}^N \frac{(x_i - \bar{x})^2}{N}$$

Onde,

$x_i$  é o valor de **cada elemento da série**;

$\bar{x}$  é o valor da **Média Aritmética Simples**;

$N$  é o **número total da população**.

– Amostra

$$S^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}$$

Onde,

$x_i$  é o valor de **cada elemento da série**;

$\bar{x}$  é o valor da **Média Aritmética Simples**;

$n$  é o **número de elementos da Amostra**;

$(n - 1)$  é por ser uma estimativa no caso da Amostra, trabalhando assim com um grau a menos de liberdade.

- Cálculo dados agrupados:
  - Para dados agrupados, sem intervalo de classe (**Variáveis Discretas**):

\* População

$$\sigma^2 = \frac{\sum (x_i - \bar{X})^2 \cdot f_i}{\sum f_i}$$

Onde,

$x_i$  é o valor de **cada elemento da série**;

$\bar{X}$  é o valor da **Média Aritmética Ponderada**;

$f_i$  é a **Frequência** da variável;

$\sum f_i$  é o somatório das **Frequências**.

\* Amostra

$$S^2 = \frac{\sum (x_i - \bar{X})^2 \cdot f_i}{n - 1}$$

Onde,

$x_i$  é o valor de **cada elemento da série**;

$\bar{X}$  é o valor da **Média Aritmética Ponderada**;  
 $f_i$  é a **Frequência** da variável;  
 $n - 1$  ou  $\sum f_i - 1$  é o somatório das **Frequências** da Amostra menos 1.

– Para dados agrupados, com intervalo de classe (**Variáveis Contínuas**):

\* População

$$\sigma^2 = \frac{\sum (p_i - \bar{X})^2 \cdot f_i}{\sum f_i}$$

Onde,  
 $p_i$  é a **Representatividade das Classe (Ponto Médio das Classes)**;  
 $\bar{X}$  é o valor da **Média Aritmética Ponderada**;  
 $f_i$  é a **Frequência** da variável;  
 $\sum f_i$  é o somatório das **Frequências**.

\* Amostra

$$S^2 = \frac{\sum (p_i - \bar{X})^2 \cdot f_i}{n - 1}$$

Onde,  
 $p_i$  é a **Representatividade das Classe (Ponto Médio das Classes)**;  
 $\bar{X}$  é o valor da **Média Aritmética Ponderada**;  
 $f_i$  é a **Frequência** da variável;  
 $n - 1$  ou  $\sum f_i - 1$  é o somatório das **Frequências** da Amostra menos 1.

### 9.3.4 Desvio-padrão ( $\sigma$ ou $S$ )

#### 9.3.4.1 Variância x Desvio-padrão

- **Variância:**
  - Número em unidade “quadrada”.
  - Maior dificuldade de compreensão e menor utilidade na estatística descritiva.
  - Extremamente relevante na inferência estatística e em combinações de amostras.
- **Desvio-padrão:**
  - Mais usado na comparação de diferenças entre conjuntos de dados.
  - Determina a dispersão dos valores em relação a **Média**.
  - Volta-se com os dados para a unidade original.

#### 9.3.4.2 Desvio-padrão (Populacional e Amostral)

- Determina a dispersão dos valores em relação a **Média**.
- População

$$\sigma = \sqrt{\sigma^2}$$

Onde,  
 $\sigma^2$  é a **Variância Populacional**;  
 $\sigma$  é o **Desvio-padrão Populacional**.

- Amostra

$$S = \sqrt{S^2}$$

Onde,  
 $S^2$  é a **Variância Amostral**;  
 $S$  é o **Desvio-padrão Amostral**.

### 9.3.5 Coeficiente de Variação ( $CV$ )

#### 9.3.5.1 Teoria

- Medida relativa de dispersão.
- Útil para comparação em termos relativos do grau de concentração.
- O **Coeficiente de Variação** ( $CV$ ) é expresso em porcentagens.
- Diz-se que uma distribuição:
  - $CV \leq 15\%$  tem **Baixa Dispersão**.
  - $15\% < CV < 30\%$  tem **Média Dispersão**.
  - $CV \geq 30\%$  tem **Alta Dispersão**.

#### 9.3.5.2 Cálculo do Coeficiente de Variação

- População:

$$CV = \frac{\sigma}{\bar{X}} \times 100$$

Onde,  
 $\sigma$  é o **Desvio-padrão Populacional**;  
 $\bar{X}$  é a **Média Populacional**.

- Amostra:

$$CV = \frac{S}{\bar{x}} \times 100$$

Onde,  
 $S$  é o **Desvio-padrão Amostral**;  
 $\bar{x}$  é a **Média Amostral**.

## 10 Aula 125 - Análise Estatística

- Para fazer uma Análise Estatística eficiente de dados, precisamos:
  - Limpar os dados  
Remover os *OUTLIER* (valores atípicos, inconsistentes).
  - Aplicar Estatística Descritiva aos dados  
As medidas de posição (**Média**, **Mediana** e **moda**) e dispersão (**Amplitude Total**, **Desvio**, **Desvio Médio**, **Variância**, **Desvio-padrão** e **Coefficiente de Variação**) são maneiras de descrever os dados.
  - Comparar as medidas dos dados  
Principalmente medidas de dispersão, me especial **Coefficiente de Variação**, são ótimas para comparar dados.
  - Previsão de dados  
A principal técnica é de **Regressão**, porém para aplicar, necessita que os dados estejam limpos e com pouca dispersão (quanto menor, melhor).

## 11 Aula 126 - Modelagem de Banco de dados X Modelagem Data Science e BI

### 11.1 Modelagem de Banco de dados

- Evitam reduncancia, consequentemente poupam espaço em disco.
- Consomem muito processamento em função de **JOINS**. Queries lentas.
- Por boas práticas, o banco de dados deve seguir (pelo menos) as três primeiras **Formas Normais**.

#### 11.1.1 Primeira forma normal

- 3 Regras:
  1. Todo campo vetorizado se tornará outra tabela.
    - Campo vetorizado é todo campo que apresenta algo como um vetor dentro dele.
    - Varios dados do mesmo tipo (vetor).
    - Exemplo:  
*vetor* [VERDE, AMARELO, LARANJA,...]
  2. Todo campo multivalorado se tornará outra tabela.
    - Campo multivalorado é todo campo que apresenta algo como uma lista dentro dele.
    - Diversos dados de tipos diferentes (lista).
    - Exemplo:  
*list* (1, VERDE, CASA, ...)
  3. Toda tabela necessita de pelo menos um campo que identifique todo registro como sendo único (é o que chamamos de “**Chave Primaria**” ou “**Primary Key**”).
    - Tipos de **CHAVE PRIMARIA**:
      - \* NATURAL
        - Pertence ao registro intrinsecamente.
        - Muito útil, porem pouco confiavel. Depende de terceiros para existir, como o governo por exemplo.
        - Exemplo: CPF.
      - \* ARTIFICIAL
        - É criada pelo/para o banco de dados para identificar o registro.
        - Exemplo: ID.

- Mais indicado de se trabalhar, pois oferece controle total por parte do administrador do banco de dados e não depende de terceiros para existir.

### 11.1.2 Segunda forma normal

“Uma relação está na **2º forma normal** se, e somente se, estiver na **1º forma normal** e cada atributo não-chave for dependente da chave primária inteira, isto é, cada atributo não-chave não poderá ser dependente de apenas parte da chave.”

- No caso de tabelas com chave primária composta, se um atributo depende apenas de uma parte da chave primária, então esse atributo deve ser colocado em outra tabela.
- Uma relação está na **2º forma normal** quando duas condições são satisfeitas:
  - A relação estiver na **1º forma normal**.
  - Todos os atributos primos dependerem funcionalmente de toda a **chave primária**.
- Conclusões:
  - Maior independência de dados.
  - Redundâncias e anomalias: dependências funcionais indiretas.

### 11.1.3 Terceira forma normal

“Uma relação R está na **3º forma normal** se ela estiver na **2º forma normal** e cada atributo não-chave de R não possuir **dependência transitiva**, para cada chave candidata de R. Todos os atributos dessa tabela devem ser independentes uns dos outros, ao mesmo tempo que devem ser dependentes exclusivamente da **chave primária** da tabela.”

- Exemplo ilustrativo:
 

“Uma tabela não está na **Terceira Forma Normal** porque a coluna *Total* é dependente, ou é resultado, da multiplicação das colunas *Preço* e *Quantidade*, ou seja, a coluna *total* tem **dependência transitiva** de colunas que não fazem parte da **chave primária**, ou mesmo candidata da tabela. Para que essa tabela passe à **Terceira forma normal** o campo *Total* deverá ser eliminado, a fim de que nenhuma coluna tenha dependência de qualquer outra que não seja exclusivamente chave”.
- Passagem para a **3º forma normal**:
  - Para estar na **3º forma normal** precisa estar na **2º forma normal**.
  - Geração de novas tabelas com DF (Dependências Funcionais) diretas.
  - Análise de dependências funcionais entre atributos não-chave.
  - Verificar a dependência exclusiva da **chave primária**.



- Entidades na **3º forma normal** também não podem conter atributos que sejam resultados de algum cálculo de outro atributo.
- Conclusões:
  - Maior independência de dados.
  - **3º forma normal** gera representações lógicas finais na maioria das vezes.
  - Redundâncias e anomalias: dependências funcionais.

## 11.2 Modelagem Data Science

- Foca em agregações e performance.
- Não se preocupa com espaço em disco.
- Não evitam redundâncias, em função de uma melhor performance.
- Preferencialmente **Modelagem Colunar**, Tabelas com redundâncias que crescem para baixo facilmente (agregam o máximo de informações possível numa mesma tabela).
- Performa melhor que modelos **BI (Modelagem Dimensional)**, pois não utiliza tantos **JOINS**.

## 11.3 Modelagem Business Intelligence

- Foca em agregações e performance.
- Não evitam redundâncias, em função de uma melhor performance.
- Tem um desempenho (performance) pior que em **Data Science** pois o **Modelo Dimensional** ainda implica em uso de **JOINS**, unindo **fato** com **dimensões**, para formar as **QUERYs** (consultas).
- Não se preocupa com espaço em disco.
- Modelagem mínima, **Data Warehouse (DW)**.
- *Modelagem Dimensional*, ou *Multidimensional* (**STAR SCHEMA** e **SNOWFLAKE SCHEMA**).

### 11.3.1 Modelagem Dimensional


- **Modelagem dimensional** (ou **multidimensional**) é uma técnica de projeto lógico normalmente usada para **Data Warehouse** que contrasta com a **modelagem entidade-relacionamento**.
- A construção de um modelo dimensional bem desenhado deve ter como princípio a simplicidade, afinal modelos muito complexos tentem a ser problemáticos a longo prazo, tornando-se “pesados” e de difícil manutenção, então aqui podemos aplicar uma regra básica, “se está muito complexo, está errado”, ou seja, modelagens muito complexas precisam ser reavaliadas e simplificadas.
- A modelagem dimensional é a única técnica viável para bancos de dados que devem responder consultas em um **Data Warehouse**.
- A **modelagem entidade-relacionamento** é muito útil para registro de transações e para fase de administração da construção de um **Data Warehouse**, mas deve ser evitada na entrega do sistema para o usuário final.
- A modelagem multidimensional foi definida sobre dois pilares:
  - Dimensões Conformados  
Dimensões conformados diz respeito a entidade que servem de perspectivas de análise em qualquer assunto da organização. Uma dimensão conformada possui atributos conflitantes com um ou mais **data-marts** do **data warehouse**.
  - Fatos com granularidade única  
Por grão de fato entende-se a unidade de medida de um indicador de desempenho. Assim, quando fala-se de unidades vendidas, pode-se estar falando em unidades vendidas de uma loja em um mês ou de um dado produto no semestre. Obviamente, esse valores não são operáveis entre si.  
A modelagem multidimensional visa construir um data warehouse com dimensões conformados e fatos afins com grãos os mais próximos possíveis.
- Esse tipo de modelagem tem dois modelos *MODELO ESTRELA* (**STAR SCHEMA**) e *MODELO FLOCO DE NEVE* (**SNOWFLAKE SCHEMA**).

### 11.3.2 STAR SCHEMA


- Neste foi um modelo o objetivo é:
  - Simplificar a visualização dimensional
  - Facilitando a distinção entre as **dimensões** e os  **fatos**.
  - Classifica as tabelas de modelo como **Dimensão** ou **Fato**.
- Classificação de tabelas:
  - **Fatos:**
    - \* **Fatos** são métricas (algo que pode ser medido ou quantificado), resultantes de um evento do processo de negócio. Ou seja, um acontecimento do negócio, que traz uma métrica (ou medida) associada a ele.
    - \* Uma tabela **Fato** armazena as métricas relacionadas a determinado evento, por exemplo, uma fato de Vendas pode armazenar quantidade de itens vendidos, valor dos itens vendidos, entre outras métricas.
  - **Dimensões:**
    - \* As **dimensões** representam os contextos para análise de um fato.
    - \* Proporcionando diferentes perspectivas de análise para o usuário e normalmente interpretadas como os “filtros possíveis” para determinada tabela **fato**.
- Modelo Teórico:



- Modelo Prático:



- Exemplo:



### 11.3.3 SNOWFLAKE SCHEMA

## 12 Observações

### 12.1 Exportação de dados

- Uma das maneiras mais fácil de exportar dados é através da extensão “.csv”.
- O **PostgreSQL** oferece opções para facilmente exportar dados em “.csv”.
- Passo a passo:
  - Basta fazer a consulta que deseja exportar, pela aba “**Query Tools**”.
  - Lembrando de colocar *alias* nas colunas/campos que levam funções, para melhor entendimento de quem for fazer a leitura do arquivo exportado.
  - Na janela em que aparece o resultado da consulta, tem a aba “Data Output” (na qual, por default, já é a aba em que aparecem os resultados das consultas), tem o ícone “*Save results to file*”.
  - Ao clicar no ícone “*Save results to file*”, é oferecido a opção de salvar a consulta como “.csv”.

### 12.2 Breve explicação de Business Intelligence e Data Science

- Business Intelligence (BI):
  - Esta preocupado com entender o que aconteceu no passado.
- Data Science:
  - Através dos dados, tentar prever tendências futuras.

## **13 Andamento dos Estudos**

### **13.1 Assunto em andamento**

Atualmente estou estudando Módulo 30 - AULA 125.